

BICentral - Sistema de Inteligencia Institucional

Universidade Federal do Tocantins (UFT)

Documento:	Visao Geral do Sistema BICentral
Versao:	1.0
Equipe:	PROAP / COPLAN
Visibilidade:	Publico
Data:	2025

1. Introducao

O BICentral e um sistema de inteligencia institucional desenvolvido para a Universidade Federal do Tocantins (UFT), com o objetivo de centralizar, organizar e disponibilizar informacoes institucionais por meio de uma interface conversacional baseada em inteligencia artificial. O sistema utiliza uma arquitetura RAG (Retrieval-Augmented Generation) que combina recuperacao semantica de documentos com geracao de respostas por modelos de linguagem de grande escala (LLMs).

A proposta surgiu da necessidade identificada nos setores administrativos da UFT, especialmente na Pro-Reitoria de Avaliacao e Planejamento (PROAP) e na Coordenacao de Planejamento (COPLAN), de facilitar o acesso a informacoes contidas em documentos institucionais como o Plano de Desenvolvimento Institucional (PDI), relatorios de gestao, normativas internas e dados de desempenho academico.

2. Objetivos do Sistema

2.1 Objetivo Geral

Desenvolver um agente conversacional inteligente capaz de responder perguntas sobre documentos institucionais da UFT com precisao, rastreabilidade e controle de acesso por equipe, utilizando tecnicas de processamento de linguagem natural e busca semantica vetorial.

2.2 Objetivos Especificos

- Implementar pipeline de ingestao de documentos nos formatos PDF e XLSX, com extracao, limpeza e fatiamento de texto.
- Gerar representacoes vetoriais (embeddings) dos chunks de texto utilizando o modelo gemini-embedding-001.
- Armazenar os embeddings no banco de dados vetorial Supabase com extensao pgvector.
- Implementar busca por similaridade semantica com filtro de visibilidade por equipe.
- Integrar o mecanismo de recuperacao com o modelo de linguagem Gemini 2.5 Flash para geracao de respostas contextualizadas.

- Implementar fallback automatico para o modelo Ollama local em caso de indisponibilidade da API Gemini.
- Garantir controle de acesso baseado em equipes, distinguindo documentos publicos e privados.

3. Arquitetura Tecnica

O BICentral foi construido sobre uma arquitetura de microsservicos com separacao clara entre frontend e backend. O backend e desenvolvido em Java com o framework Spring Boot, utilizando o LangChain4j para integracao com modelos de linguagem e embeddings. O frontend e construido em React com Vite.

3.1 Stack Tecnologico

Camada	Tecnologia	Funcao
Backend	Java + Spring Boot	API REST, logica de negocio
IA / LLM	Gemini 2.5 Flash	Geracao de respostas conversacionais
IA / Fallback	Ollama (llama3)	LLM local para alta disponibilidade
Embeddings	gemini-embedding-001	Vetorizacao semantica dos chunks
Embeddings Fallback	nomic-embed-text (Ollama)	Vetorizacao local para resiliencia
Banco Vetorial	Supabase + pgvector	Armazenamento e busca por similaridade
Banco Relacional	PostgreSQL (Supabase)	Dados de usuarios, equipes e documentos
Frontend	React + Vite	Interface conversacional do usuario
Framework IA	LangChain4j	Abstracao de modelos e pipelines de IA

3.2 Pipeline de Ingestao de Documentos

O processo de ingestao transforma documentos brutos em chunks vetorizados prontos para busca semantica. O pipeline segue as seguintes etapas: (1) upload do documento pelo usuario administrador; (2) extracao do texto bruto via PDFBox (para PDF) ou Apache POI (para XLSX); (3) limpeza do texto com remocao de ruidos, numeros de pagina isolados e normalizacao de espacos; (4) fatiamento em chunks de 512 palavras com sobreposicao de 64 palavras para preservacao de contexto; (5) geracao de embeddings com dois modelos simultaneamente (Gemini e Ollama); (6) persistencia dos vetores e metadados no Supabase.

3.3 Mecanismo de Fallback de Embeddings

Uma decisao arquitetural central do BICentral e a geracao dupla de embeddings durante a ingestao. Para cada chunk processado, o sistema gera dois vetores: um utilizando o modelo gemini-embedding-001 e outro utilizando o modelo nomic-embed-text via Ollama. Ambos os vetores sao armazenados na tabela embeddings do Supabase nos campos embedding_gemini e embedding_ollama, ambos com 768 dimensoes.

Durante a consulta do usuário, o sistema tenta primeiro gerar o embedding da pergunta via Gemini. Em caso de falha (limite de requisições, timeout ou indisponibilidade da API), o sistema aciona automaticamente o Ollama local como provedor alternativo, garantindo continuidade do serviço sem inconsistência semântica, já que o vetor da pergunta é comparado sempre com o vetor do mesmo provedor.

4. Controle de Acesso por Equipe

O BICentral implementa um modelo de visibilidade de documentos baseado em equipes institucionais. Cada documento ingerido recebe uma classificação de visibilidade: PÚBLICO ou PRIVADO. Documentos públicos são acessíveis a todos os usuários autenticados do sistema. Documentos privados são acessíveis apenas aos membros da equipe que realizou a ingestão.

As equipes cadastradas no sistema correspondem aos setores administrativos da UFT, tais como: PROAP, COPLAN, SUCOM, PROAD, PROGRAD, PROPESQ, entre outros. O controle é aplicado diretamente na função de busca vetorial no Supabase, que filtra os chunks retornados com base no `equipe_id` do usuário autenticado e na visibilidade do documento.

5. Plano de Desenvolvimento Institucional (PDI)

O PDI da UFT é um dos principais documentos institucionais que o BICentral visa tornar acessível de forma conversacional. O PDI 2021-2025 está estruturado em cinco eixos temáticos: Eixo 1 - Planejamento e Gestão Institucional; Eixo 2 - Perfil Institucional; Eixo 3 - Graduação; Eixo 4 - Pós-Graduação, Pesquisa e Inovação; Eixo 5 - Extensão e Cultura.

O sistema permite que servidores dos setores administrativos consultem metas, indicadores e ações do PDI por meio de linguagem natural, sem necessidade de navegar por documentos extensos. Por exemplo, uma consulta como 'Quais são as metas de expansão de cursos de pós-graduação para 2024?' aciona o pipeline RAG que recupera os trechos relevantes do PDI e gera uma resposta sintetizada.

6. Considerações de Segurança e LGPD

O BICentral foi projetado com atenção às diretrizes da Lei Geral de Proteção de Dados (LGPD). Todos os documentos ingeridos têm rastreabilidade de origem por meio do campo `nome_arquivo` e `grupo_id`, que permitem identificar o conjunto de chunks gerados a partir de cada documento. Dados pessoais de servidores e alunos não devem ser ingeridos no sistema sem tratamento prévio de anonimização.

A autenticação é realizada via JWT com verificação de email. O controle de acesso por equipe garante que informações sensíveis de um setor não sejam acessíveis a usuários de outros setores. Convites para participação em equipes têm prazo de expiração e token de uso único.

7. Próximos Passos

- Implementar interface de upload de documentos no frontend para administradores.

- Desenvolver o componente de chat conversacional integrado ao pipeline RAG.
- Adicionar suporte a documentos no formato DOCX.
- Implementar historico de conversas por usuario.
- Desenvolver dashboard de monitoramento de ingestoes e consultas.
- Realizar testes de carga para avaliar o desempenho da busca vetorial com grande volume de chunks.
- Documentar a API REST com Swagger/OpenAPI.